Importare i microdati Istat

(file standard dei microdati)

Ultimo aggiornamento: 17 ottobre 2026

Nicola Tommasi
nicola.tommasi@univr.it

C.I.D.E.
Centro Interdipartimentale di documentazione Economica
Università di Verona

Indice

1 L'idea 1

2 Organizzazione dei dei files 1

3 Procedura di importazione 3

4 Possibili miglioramenti 7

1. L'idea

Molte tipologie di microdati standard di Istat (https://www.istat.it/dati/microdati/) condividono la stessa struttura di distribuzione dei dati, dei metadati e delle classificazioni. In particolare, le informazioni contenute nella cartella 'MICRODATA', permettono di creare un database completo di descrizione delle variabili e di descrizione dei valori numerici delle variabili categoriche. La procedura Stata descrittiva di seguito, automatizza tutto il processo, riducendo il più possibile l'adattamento del codice ai vari casi.
I files forniti da Istat hanno questa struttura:

- un file 'Leggimi' in formato html
- una cartella 'METADATI' con vari files e che contiene la cartella 'Classificazioni'
- una cartella 'MICRODATI' che contiene un file txt con i microdati

La procedura è stata testata su queste tipologie di microdati standard

- Multiscopo - vita quotidiana
- HBS
- HBS dati ricostruiti
- forze lavoro longitudinali
- forze lavoro trasversali
- EUSILC

2. Organizzazione dei dei files

Per prima cosa cerchiamo di capire come sono strutturati i files distribuiti da Istat. La cartella 'METADATI' (figura 1) contiene diversi files e una cartella. Il file che servirà a noi è quello che contiene il tracciato dei dati. È un file html ed è evidenziato con una freccia nella figura.

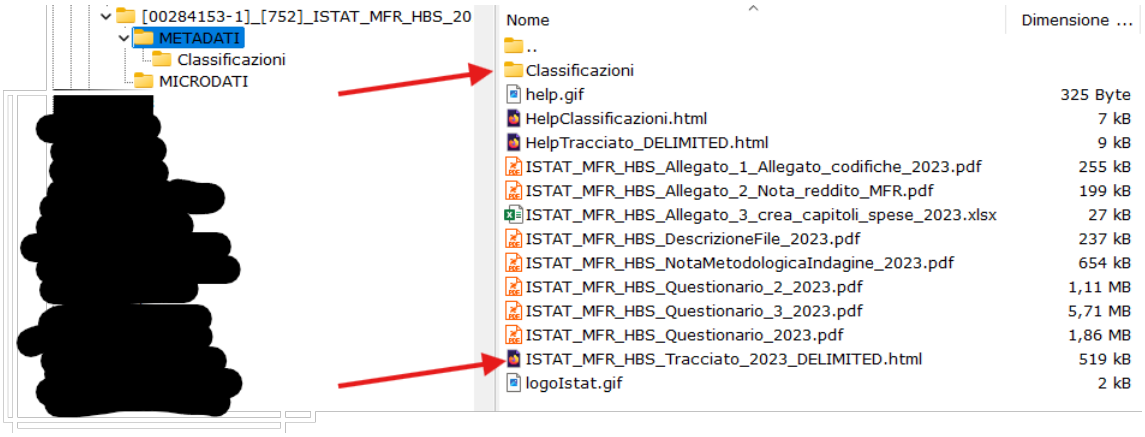


Figura 1: Cartella METADATI

Al suo interno (vedi figura 2) troviamo tre informazioni utili al nostro scopo

1. il nome da assegnare alle variabili (colonna Acronimovariabile)
2. link per accedere alla descrizione dei valori della variabile (colonna TipoVariabile) (vedi anche figura 4)
3. la descrizione da associare a ciascuna variabile (colonna Denominazione Variabile)

INDAGINE: Spese delle famiglie Anno_2023

num. ordine	Posizione	Lunghezza	Acronimovariabile	TipoVariabile	Valori speciali	Aggregazione	Note	TipoRecord	Denominazione Variabile
1		2	c_Ncmp_altro	Categorica	-				Numero di persone legate da vincoli economici
2		2	c_Ncmp_fatto	Categorica	-				Numero totale dei componenti la famiglia di fatto
3		1	sesso_1	Categorica	-				Sesso del componente 1
4		2	c_relaz_1	Categorica	-				Relazione di parentela del componente 1
5		1	pnasc_1	Categorica	-				Stato di nascita del componente 1
6		3	c_etacalc_1	Categorica	-				Eta' calcolata del componente 1
7		1	cittad_1	Categorica	-				Cittadinanza del componente 1
8		1	pnasc_padre_1	Categorica	-				Stato di nascita del padre del componente 1
9		1	pnasc_madre_1	Categorica	-				Stato di nascita della madre del componente 1
10		2	staciv_1	Categorica	-				Stato civile del componente 1
11		2	c_titstu_1	Categorica	-				Titolo di studio del componente 1

Figura 2: File html del tracciato

I link della colonna TipoVariabile, rimandano ai files contenuti nella cartella 'Classificazioni' (figura 3). Ogni variabile categorica ha un collegamento con un file della cartella 'Classificazioni'

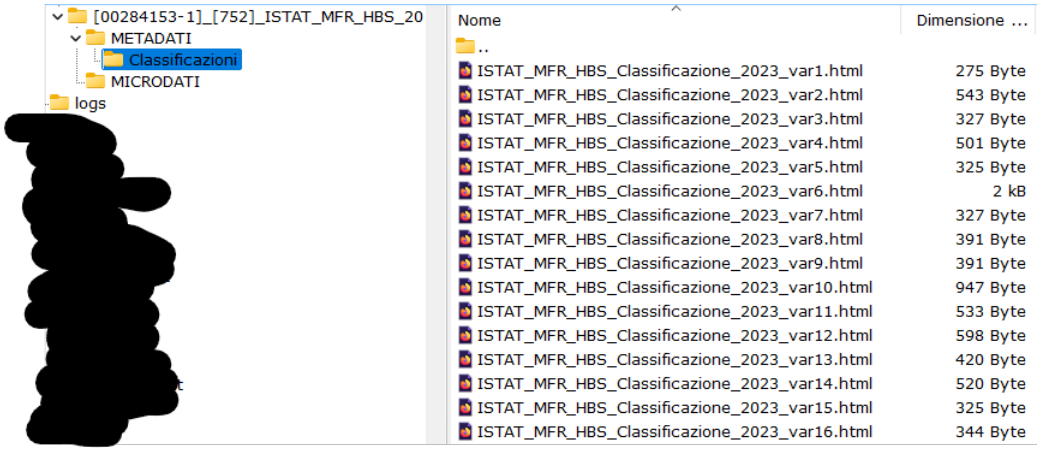


Figura 3: Lista files delle classificazioni

Questi files sono strutturati come si può vedere nella figura 4

ELENCO MODALITA' della variabile: c_relaz_1 (6,0) Anno: 2023

Modalita'	Descrizione	Codice aggregazione	Note
1	persona di riferimento (PR)		
2	coniuge/convivente/unito civilmente con PR		
3	Figlio		
4	altro		

Figura 4: Contenuto files delle classificazioni

Una tabella con valore numerico nella prima colonna e descrizione nella seconda. Quella in figura è relativa alla variabile `c_relaz_1`.
La cartella 'MICRODATI' contiene il file dei dati in formato testo delimitato (figura 5).

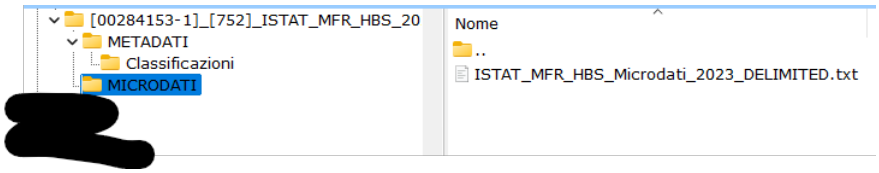


Figura 5: Cartella MICRODATI

Il delimitatore è il carattere ^ (figura 6)

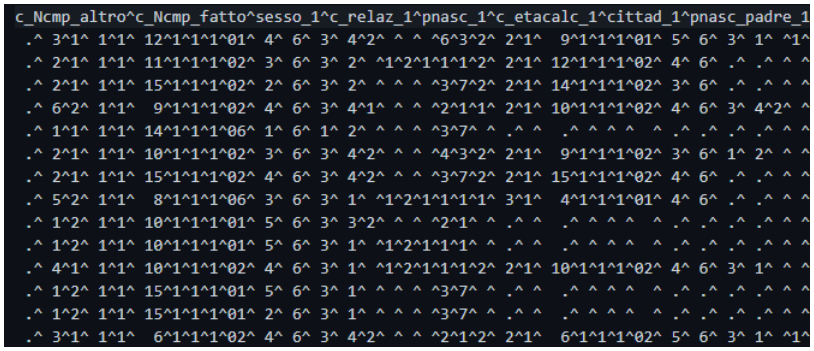


Figura 6: File dei microdati

3. Procedura di importazione

Viene ora descritta la procedura di importazione dei dati. Il codice sarà spezzato in diverse parti e commentato. Il file completo è disponibile assieme al pdf nella pagina GitHub dedicata.

```
1  clear all
2  local input1 ISTAT_MFR_HBS_Tracciato_2023_DELIMITED.html
3  local input2 ISTAT_MFR_HBS_Microdati_2023_DELIMITED.txt
4  local output1 HBS2023.dta

5  frame change default

6  import delimited "METADATI/`input1'", delimiter("|||") clear encoding(UTF-8)
7  keep if strmatch(v1,"<tr *")
8  replace v1=subinstr(v1," ","",.)
9  replace v1=subinstr(v1,"</tr>","",.)
10 replace v1=subinstr(v1,"<tr ","",.)

11 replace v1=subinstr(v1,"</td><td>","|||",.)
12 replace v1=subinstr(v1,"><td>","|||",.)
13 split v1, gen(var) parse("|||")
14 drop in 1
15 drop v1
```

Nelle righe 2-4 si impostano le local `input1` con il nome del file del tracciato, `input2` con il nome del file dei dati e `output2` con il nome del file dta prodotto alla fine della procedura. Il file del tracciato viene importato (riga 6) e sottoposto a pulitura. A riga 7 vengono selezionate solo le righe di interesse. Da riga 8 a riga 10 si pulisce il codice html importato. Da riga 11 a riga 15 si sostituiscono i tag <td> con una tripla pipe.

Questa verrà usata nel comando `split` (riga 13) per creare le variabili da usare per il label delle variabili e dei valori.

```
1  replace var5=lower(var5)

2  replace var6=regexs(1) if regexm(var6, `"<a href="./(.*)">"')
3  replace var6="" if var6=="-"

4  replace var11=regexs(1) if regexm(var11, `""(.*)""') & strmatch(var11,`""*"') /* --> label var */
5  replace var11=subinstr(var11, `"""',"",.)
6  replace var11=subinstr(var11, `"u'"',"ù",.)
7  replace var11=subinstr(var11, `"a'"',"à",.)
8  replace var11=subinstr(var11, `"o'"',"ò",.)
9  replace var11=subinstr(var11, `"i'"',"ì",.)
10 replace var11=subinstr(lower(var11),`"e'"',"è",.)

11 replace var11=subinstr(var11, "spesa per il ","",1)
12 replace var11=subinstr(var11, "spesa per ","",1)
13 replace var11=subinstr(var11, "per altre abitazioni di proprietà","x altre ab. di propr.",1)
14 forvalues c=12(-1)1 {
15   replace var11=subinstr(var11, " del componente `c'","",1)
16 }

17 list var11 if strlen(var11)>80, sep(0) noobs /* up to 80 characters*/

18 gen labelvar = "label var " + lower(var5) + `" ""' + lower(var11) + `"""'
```

Il comando `split` ha creato una serie di variabili; di queste, solo `var5`, `var6` e `var11` sono inutili, le altre possono essere cancellate.

`var5` contiene il nome delle variabili. A me piace che siano tutte in caratteri minuscoli (riga 1), ma potete fare la scelta che vi piace di più.

`var6` riporta il link per accedere al file con la descrizione dei valori, ovvero i files html contenuti nella cartella 'METADATI/Classificazioni'. Il dato però non è pulito e la riga 2 lo trasforma da così

```
<a href="./Classificazioni/ISTAT_MFR_HBS_Classificazione_2023_var1.html">Categorica</a>
```

a così

```
Classificazioni/ISTAT_MFR_HBS_Classificazione_2023_var1.html
```

I casi in cui la variabile non ha descrizione dei valori (variabili numeriche continue o stringa), riportano il simbolo "-" e vengono convertite in missing (riga 3).

E adesso viene la parte più laboriosa e complicata. Da riga 4 a riga 13 si interviene su `var11` per renderla compatibile con le regole di Stata relative al comando `label variable` e affinchè la descrizione associata a ciascuna variabile sia consona alle nostre aspettative. A riga 4 si tolgono i testi tra parentesi tonde, a riga 5 le virgolette. Questo per accorciare il più possibile la lunghezza della descrizione e rimanere nel limite di Stata degli 80 caratteri.

Da riga 6 a riga 10 si ricostruiscono le lettere accentate dato che vengono riportate sempre come vocale più simbolo '.

Da riga 11 a riga 16 altri interventi per migliorare la descrizione delle variabili. A riga 11 e 12 si toglie l'incipit per una serie di spese, a riga 13 si abbrevia la descrizione; per esempio

```
spesa per il riscaldamento/condizionamento centralizzato per altre abitazioni di proprietà
```

diventa

```
riscaldamento/condizionamento centralizzato x altre ab. di propr.
```

Da riga 14 a riga 16, altra riduzione della lunghezza del testo di descrizione. Infine a riga 17, viene stampata la lista delle descrizioni che eccedono il mite di Stata di 80 caratteri per il comando `label variable`

```
...
servizio di consegna a domicilio di spesa per bevande alcoliche e/o generi non alimentari di largo consumo
servizio di consegna a domicilio di spesa mista, cioè sia generi alimentari sia bevande alcoliche e/o generi non alime
abbonamenti a servizi di consegna a domicilio della spesa per soli generi alimentari
abbonamenti a servizi di consegna a domicilio della spesa solo per  bevande alcoliche e/o generi non alimentari di lar
abbonamenti a servizi di consegna a domicilio di spesa mista, che include cioè sia generi alimentari sia bevande alcol
servizi di trasformazione di frutta o cereali per la produzione di bevande alcoliche
abbonamenti per solo traffico dati per telefono cellulare, tablet, cubo ed altri dispositivi
solo traffico dati, cioè connessione internet, da rete fissa, ad esempio adsl o fibra
pacchetti telefono-internet o telefono-internet-tv e/o per altri pacchetti per telecomunicazioni tutto compreso
noleggio di modem, router e simili per pacchetti per telecomunicazioni tutto compreso
spesa condominiale per la manutenzione, riparazione o ristrutturazione delle parti comuni
...
```

Da questa lista è possibile prendere punto per implementare ulteriori strategie di riduzione della lunghezza della variabile `var11`.

L'ultima riga costruisce il comando che verrà usato in seguito per fare i label delle variabili usando i dati delle variabili `var5` e `var11`. Il risultato finale è questo:

```
label var c_ncmp_altro "numero di persone legate da vincoli economici"
label var c_ncmp_fatto "numero totale dei componenti la famiglia di fatto"
label var sesso_1 "sesso"
label var c_relaz_1 "relazione di parentela"
label var pnasc_1 "stato di nascita"
label var c_etacalc_1 "età calcolata"
label var cittad_1 "cittadinanza"
label var pnasc_padre_1 "stato di nascita del padre"
label var pnasc_madre_1 "stato di nascita della madre"
label var staciv_1 "stato\texttt{labels\_frame} civile"
label var c_titstu_1 "titolo di studio"
label var c_stucor_1 "iscrizione a corso di studio"
label var c_ateco_1 "attività economica"
label var c_pospro_1 "posizione professionale"
label var pers_dipend_1 "personale alle dipendenze"
label var orario_1 "orario di lavoro"
label var rapp_1 "rapporto di lavoro"
label var contratto_1 "come è regolato il rapporto di lavoro"
label var c_redd_1 "fonte di reddito"
label var cond_1 "condizione"
label var sesso_2 "sesso"
label var c_relaz_2 "relazione di parentela"
label var pnasc_2 "stato di nascita"
...
```

La parte successiva è un po' più complicata e serve a costruire il `label define` per ciascuna variabile categorica. Il testo da inserire nel comando viene preso dai files .html di figura 3 e figura 4.

```
gen labdefcomm = ""
qui count
local NVAR = `r(N)'
forvalues r=1(1)`NVAR' {
  if var6[`r'] != "" {
    local VAR =  lower(var5) in `r'
    local link = var6 in `r'
    preserve
      htmltab2stata, url(METADATI/`link')
      drop in 1
      local labdefine = "label define `VAR' "
      replace myvar2 = subinstr(myvar2,`"""',"'",.  )
      replace myvar2=subinstr(myvar2,"gi�","già",.)
      replace myvar2=subinstr(myvar2,"s�","sì",.)
      replace myvar2=subinstr(myvar2,"S�","Sì",.)
      replace myvar2=subinstr(myvar2,"pu�","può",.)
      replace myvar2=subinstr(myvar2,"pi�","più",.)
      replace myvar2=subinstr(myvar2," � "," è ",.)
      replace myvar2=subinstr(myvar2,"� importante","É importante",.)
      replace myvar2=subinstr(myvar2,"dall�assicurazione","dall'assicurazione",.)
      replace myvar2=subinstr(myvar2,"propriet�","proprietà",.)
      replace myvar2=subinstr(myvar2,"difficolt�","difficoltà",.)
      replace myvar2=subinstr(myvar2,"piu volte","più volte",.)
      replace myvar2=subinstr(myvar2,"l'anno","l'anno",.)
      replace myvar2=subinstr(myvar2,"migliorer�","migliorerà",.)
      replace myvar2=subinstr(myvar2,"rester�","resterà",.)
      replace myvar2=subinstr(myvar2,"peggiorer�","peggiorerà",.)

      qui count
      forvalues n=1(1)`r(N)' {
        local VAL = myvar1 in `n'
        if inlist("`VAL'",".","") local VAL = ".a"
        local VALDESC = myvar2  in `n'
        local labdefine = `"`labdefine' `VAL' "`VALDESC'" "'
      }
      di `"`labdefine'"'
    restore
    replace labdefcomm = `"`labdefine'"' in `r'
  }
}

keep labelvar labdefcomm
frame copy default labels_frame, replace
```

A riga 1 viene creata la variabile `labdefcomm` che verrà popolata con il codice successivo. Poi viene inizializzato un ciclo per ciascuna osservazione del dataset (righe 2-4). Se alla riga *r*-esima del dataset, la variabile `var6` non è vuota, ovvero contiene un link, questo viene inserito nella local `link`. Il contenuto dei questa local viene passato al comando `htmltab2stata` (riga 9), per importare il contenuto della tabella html. Ciò che viene importato è una cosa di questo tipo:

```
Classificazioni/ISTAT_MFR_HBS_Classificazione_2023_var4.html
```

```
+-------------------------------------------------------------------------------------+
|    myvar1                                    myvar2                myvar3   myvar4 |
|-------------------------------------------------------------------------------------|
| Modalita'                                Descrizione   Codice aggregazione     Note |
|         1                 persona di riferimento (PR)                           |
|         2   coniuge/convivente/unito civilmente con PR                           |
|         3                                    Figlio                              |
|         4                                     altro                              |
+-------------------------------------------------------------------------------------+
```

Da riga a 12 a riga 27 viene pulito il contenuto di `myvar2`, poi, riga per riga, viene costruita la local `labdefine` (righe 28-37), che in questo caso risulterà essere così

```
label define c_relaz_1 1 "persona di riferimento (PR)" 2 "coniuge/convivente/unito civilmente con PR" 3 "Figlio" 4 "al
```

Poi, il contenuto di questa local viene assegnato all'osservazione *r*-esima della variabile `labdefcomm`. Alla fine del ciclo viene creato un database, poi assegnato al frame `labels_frame` che si presenta così:

labelvar	
label var c_ncmp_altro "numero di persone legate da vincoli economici"	label define c_ncmp_altro 1 "Almeno uno"
label var c_ncmp_fatto "numero totale dei componenti la famiglia di fatto"	label define c_ncmp_fatto 1 "1" 2 "2" 3 "3" 4 "4" 5 "5" 6 "6 o piu'"
label var sesso_1 "sesso"	label define sesso_1 1 "maschio" 2 "femmina"
label var c_relaz_1 "relazione di parentela"	label define c_relaz_1 1 "persona di riferimento (PR)" 2 "coniuge/convivente/unito civ
label var pnasc_1 "stato di nascita"	label define pnasc_1 1 "Italia" 2 "estero"
label var c_etacalc_1 "età calcolata"	label define c_etacalc_1 1 "meno di 6 anni" 2 "6-14 anni" 3 "15-17 anni" 4 "18-24 a
label var cittad_1 "cittadinanza"	label define cittad_1 1 "Italia" 2 "estero"
label var pnasc_padre_1 "stato di nascita del padre"	label define pnasc_padre_1 1 "Italia" 2 "estero" 3 "non sa"
label var pnasc_madre_1 "stato di nascita della madre"	label define pnasc_madre_1 1 "Italia" 2 "estero" 3 "non sa"
label var staciv_1 "stato civile"	label define staciv_1 1 "Celibe/ nubile" 2 "Coniugato/a coabitante col coniuge" 3 "C
label var c_titstu_1 "titolo di studio"	label define c_titstu_1 1 "nessun titolo" 2 "elementari" 3 "medie" 4 "superiori" 5 "lau
label var c_stucor_1 "iscrizione a corso di studio"	label define c_stucor_1 1 "nessun titolo" 2 "elementari" 3 "medie" 4 "superiori" 5 "la
label var c_ateco_1 "attività economica"	label define c_ateco_1 1 "settore primario" 2 "settore secondario" 3 "settore terziario"
label var c_pospro_1 "posizione professionale"	label define c_pospro_1 1 "dirigenti e impiegati" 2 "operai e assimilati" 3 "imprenditori
label var pers_dipend_1 "personale alle dipendenze"	label define pers_dipend_1 1 "si"' 2 "no"
label var orario_1 "orario di lavoro"	label define orario_1 1 "a tempo pieno" 2 "a tempo parziale"
label var rapp_1 "rapporto di lavoro"	label define rapp_1 1 "a tempo determinato" 2 "a tempo indetrminato"
label var contratto_1 "come è regolato il rapporto di lavoro"	label define contratto_1 1 "Contratto scritto" 2 "Accordo verbale"
label var c_redd_1 "fonte di reddito"	label define c_redd_1 1 "Reddito da lavoro dipendente" 2 "Reddito da lavoro autonon

Figura 7: Frame labels_frame

Lo step successivo prevede

1. l'importazione dei dati
2. il label delle variabili
3. il label dei valori delle variabili categoriche

```
1  import delimited "MICRODATI/`input2'", clear delim("^")
2  local cnt = 1
3  foreach V of varlist * {
4    frame labels_frame: local labelvarcommand = labelvar in `cnt'
5    `labelvarcommand'
6    frame labels_frame: local labeldefinecommand = labdefcomm in `cnt'
7    if `"`labeldefinecommand'"' != "" {
```

```
8       destring `V', replace
9       `labeldefinecommand'
10      label values `V' `V'
11    }
12    local cnt = `cnt' + 1
13  }

14  compress
15  save `output1', replace
```

Riga 1 importa i dati. A riga 2 viene inizializzato il contatore `cnt`: servirà da collegamento tra ciascuna variabile del file dei microdati e corrispondente osservazione nel frame `labels_frame`. Infatti, l'*n*-esima variabile del file dei micordati corrisponde esattamente all'*n*-esima osservazione del frame `labels_frame`.

A riga 4, dal frame `labels_frame` si assegna alla local `labelvarcommand` il contenuto della variabile `labelvar` della riga `cnt` (vedi figura 7). In pratica `labelvarcommand` è una stringa che contiene il `label var`. Riga 5 esegue tale comando.

Da riga 6 a riga 10 si ripete lo stesso schema: dal frame `labels_frame` si assegna alla local `labeldefinecommand` il contenuto della variabile `labdefcomm` della riga `cnt` (vedi figura 7). `labeldefinecommand` è una stringa che contiene il `label define`. Riga 9 esegue tale comando e riga 10 assegna il label alla variabile. Questa operazione viene eseguita solo per le variabili che hanno un `label define` non vuoto (riga 7).

Al termine del ciclo, si salva il dataset (riga 15). Ok, ho finito, spero che possa esservi utile! Se avete problemi, mail a nicola.tommasi@univr.it.

4. Possibili miglioramenti

- label ripetute (sesso_1, sesso_2, ...)
- fornire una lista di replace per i `label variable` di ciascun database
- fornire una lista di replace per i `label define` di ciascun database

Riferimenti bibliografici

[1] Jan Ditzen (jan.ditzen@unibz.it), 2019. htmltab2stata: parses html code from websites.
https://github.com/JanDitzen/htmltab2stata

[2] Microdati standard
https://www.istat.it/dati/microdati/standard/

[3] Nicola Tommasi, 2026. Pagina su GitHub.